Σχεδίαση και Υλοποίηση Μηχανισμού Κρυφής Μνήμης για Κατανεμημένο Σύστημα Αποθήκευσης σε Περιβάλλον Υπολογιστικού Νέφους

Αλέξιος Πυργιώτης
Εθνικό Μετσόβιο Πολυτεχνείο
October 16, 2013

Σχεδίαση και Υλοποίηση Μηχανισμού Κρυφής Μνήμης για Κατανεμημένο Σύστημα Αποθήκευσης σε Περιβάλλον Υπολογιστικού Νέφους

1. Καλημέρα σας, ονομάζομαι Αλέξιος Πυργιώτης
   Θα σας παρουσιάσω τη διπλωματική μου με τίτλο:..
2. Ακούγεται κάπως περίεργο στα ελληνικά...
   αυτό που πραγματεύται είναι την δημιουργία ενός caching μηχανισμού για το Archipelago, ένα distibuted, storage layer
3. Συγκεκριμένα, στην παρουσίαση αυτή θα μιλήσουμε για τον cached, δηλαδή τον caching μηχανισμό μας, αλλά και για το synapsed, ένα συμπληρωματικό εργαλείο που στόχος του είναι να δώσει στον cached δικτυακές δυνατότητες
4. Σημείωση: Για οικονομία του λόγου, δε θα προβώ σε εξήγηση βασικών όρων όπως VMs, storage. Για κάθε άγνωστη έννοια, παρακαλώ να με διακόψετε.

Αλέξιος Πυργιώτης

Εθνικό Μετσόβιο Πολυτεχνείο

October 16, 2013

1. Ο κορμός της παρουσίασης είναι ο εξής:
   - Αρχικά, παρουσιάζουμε κάποια εισαγωγικά που αφορούν το background της εργασίας μας. Αναφέρουμε τι είναι το Synnefo, τι είναι η υπηρεσια okeanos και τι είναι το Αρχιπέλαγο
   - Έπειτα, δείχνουμε τον τρόπο με τον οποίο η υποδομή μας χειριζεται αιτήματα δεδομένων από ένα VM.

Contents

Table of Contents
Introduction
VM Volume storage
Caching
Cached design
Cached evaluation
Synapsed
Conclusion

Table of Contents

Ας ξεκινήσουμε με την παρούσα κατάσταση.
Το software που τα ξεκίνησε όλα είναι το Synnefo

..by GRNET -> Και φυσικά τα παιδιά που βλεπετε εδώ

- Compute service, είναι η υπηρεσία η οποία προμηθεύει τους χρήστες με VMs και επιτρέπει το χειρισμό τους
- Network service, είναι η υπηρεσία η οποία δίνει τη δυνατότητα στους χρήστες να δημιουργήσουν ιδιωτικά δίκτυα και να συνδέσουν τα VMs τους σε αυτά.
- Storage service, που παρέχει αποθηκευτικό χώρο στους χρήστες.
- Image Service, υπεύθυνο για το deployment ενός VM από ένα image. Επίσης, κάνει και παραμετροποιήσεις (παράδειγμα ssh κλειδιά)

Synnefo

synnefo

Open source, production-ready, cloud software.
Designed since 2010 by GRNET.

Synnefo, as most cloud software, has the following services:

- Compute Service
- Network Service
- Storage Service
- Image Service
- Identity Service

okeanos
okeanos
- IaaS service
- Targeted at the Greek Academic and Research Community
- Designed by GRNET
- In production since 2011

- IaaS είναι πρακτικά η παροχή εικονικής υποδομής σε χρήστες (δηλαδή πάρε υπολογιστή (VM), δίκτυα, αρχεία κτλ)
- Δωρεάν για τους Ακαδημαϊκους σκοπούς, ήδη γίνονται εργαστήρια στο EMP και απ' αυτό το εξάμηνο σε άλλες σχολές
- CLICK!
- Και φυσικά παίζει πάνω σε Synnefo...

okeanos

okeanos

- IaaS service
- Targeted at the Greek Academic and Research Community
- Designed by GRNET
- In production since 2011

okeanos
okeanos
- IaaS service
- Targeted at the Greek Academic and Research Community
- Designed by GRNET
- In production since 2011
- ...and of course powered by Synnefo.

- IaaS είναι πρακτικά η παροχή εικονικής υποδομής σε χρήστες (δηλαδή πάρε υπολογιστή (VM), δίκτυα, αρχεία κτλ)
- Δωρεάν για τους Ακαδημαϊκους σκοπούς, ήδη γίνονται εργαστήρια στο EMP και απ' αυτό το εξάμηνο σε άλλες σχολές
- CLICK!
- Και φυσικά παίζει πάνω σε Synnefo...

okeanos

okeanos

- IaaS service
- Targeted at the Greek Academic and Research Community
- Designed by GRNET
- In production since 2011
- ...and of course powered by Synnefo.

Table of Contents
Introduction
VM Volume storage
Caching
Cached design
Cached evaluation
Synapsed
Conclusion

Table of Contents

Intro

1. Σε μεγάλες εγκαταστάσεις, ξεφεύγουμε από το κλασσικό μοντέλο του PC μας (το μηχάνημα έχει το σκληρό του δίσκο). Συγκεκριμένα σε μια cloud υποδομή έχουμε:
2. **CLICK!**
3. Το VM που τρέχει σε ένα host server
4. **CLICK!**
5. Και τους storage servers
6. **CLICK!**
7. Το ερώτημα είναι λοιπόν, πως το VM θα αποθηκεύει τα δεδομένα του;
   Υπάρχουν διάφορες επιλογές όπως το DRBD, το RBD που χρησιμοποιούνται ευρέως και γεφυρώνουν τον αποθηκευτικό χώρο του VM με το χώρο όπου λειτουργεί.
8. Τι γίνεται όμως στην περίπτωση που θέλουμε *και* τα εξής;
9. **CLICK!**
10. Εξήγησε τους όρους

Intro

1. Σε μεγάλες εγκαταστάσεις, ξεφεύγουμε από το κλασσικό μοντέλο του PC μας (το μηχάνημα έχει το σκληρό του δίσκο). Συγκεκριμένα σε μια cloud υποδομή έχουμε:
2. CLICK!
3. Το VM που τρέχει σε ένα host server
4. CLICK!
5. Και τους storage servers
6. CLICK!
7. Το ερώτημα είναι λοιπόν, πως το VM θα αποθηκεύει τα δεδομένα του;
   Υπάρχουν διάφορες επιλογές όπως το DRBD, το RBD που χρησιμοποιούνται ευρέως και γεφυρώνουν τον αποθηκευτικό χώρο του VM με το χώρο όπου λειτουργεί.
8. Τι γίνεται όμως στην περίπτωση που θέλουμε *και* τα εξής;
9. CLICK!
10. Εξήγησε τους όρους

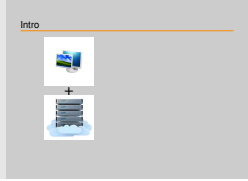

Intro

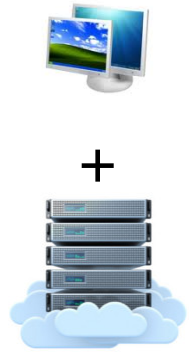

1. Σε μεγάλες εγκαταστάσεις, ξεφεύγουμε από το κλασσικό μοντέλο του PC μας (το μηχάνημα έχει το σκληρό του δίσκο). Συγκεκριμένα σε μια cloud υποδομή έχουμε:
2. CLICK!
3. Το VM που τρέχει σε ένα host server
4. CLICK!
5. Και τους storage servers
6. CLICK!
7. Το ερώτημα είναι λοιπόν, πως το VM θα αποθηκεύει τα δεδομένα του;
   Υπάρχουν διάφορες επιλογές όπως το DRBD, το RBD που χρησιμοποιούνται ευρέως και γεφυρώνουν τον αποθηκευτικό χώρο του VM με το χώρο όπου λειτουργεί.
8. Τι γίνεται όμως στην περίπτωση που θέλουμε *και* τα εξής;
9. CLICK!
10. Εξήγησε τους όρους

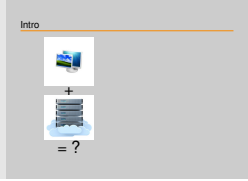

1. Σε μεγάλες εγκαταστάσεις, ξεφεύγουμε από το κλασσικό μοντέλο του PC μας (το μηχάνημα έχει το σκληρό του δίσκο). Συγκεκριμένα σε μια cloud υποδομή έχουμε:
2. CLICK!
3. Το VM που τρέχει σε ένα host server
4. CLICK!
5. Και τους storage servers
6. CLICK!
7. Το ερώτημα είναι λοιπόν, πως το VM θα αποθηκεύει τα δεδομένα του;
   Υπάρχουν διάφορες επιλογές όπως το DRBD, το RBD που χρησιμοποιούνται ευρέως και γεφυρώνουν τον αποθηκευτικό χώρο του VM με το χώρο όπου λειτουργεί.
8. Τι γίνεται όμως στην περίπτωση που θέλουμε *και* τα εξής;
9. CLICK!
10. Εξήγησε τους όρους

Intro

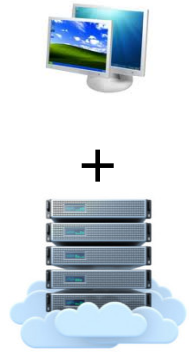

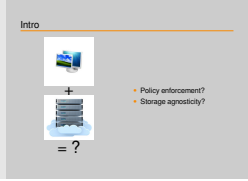

1. Σε μεγάλες εγκαταστάσεις, ξεφεύγουμε από το κλασσικό μοντέλο του PC μας (το μηχάνημα έχει το σκληρό του δίσκο). Συγκεκριμένα σε μια cloud υποδομή έχουμε:
2. CLICK!
3. Το VM που τρέχει σε ένα host server
4. CLICK!
5. Και τους storage servers
6. CLICK!
7. Το ερώτημα είναι λοιπόν, πως το VM θα αποθηκεύει τα δεδομένα του;
   Υπάρχουν διάφορες επιλογές όπως το DRBD, το RBD που χρησιμοποιούνται ευρέως και γεφυρώνουν τον αποθηκευτικό χώρο του VM με το χώρο όπου λειτουργεί.
8. Τι γίνεται όμως στην περίπτωση που θέλουμε *και* τα εξής;
9. CLICK!
10. Εξήγησε τους όρους

Intro

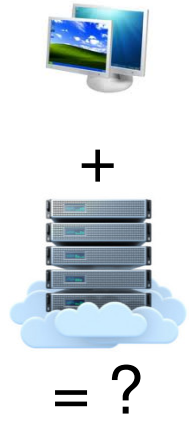

- Policy enforcement?
- Storage agnosticity?

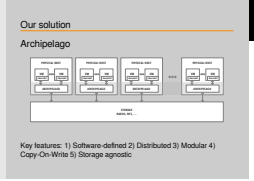

Η λύση που χρησιμοποιήσαμε είναι το Archipelago

- Software-defined: αν και είναι ένα όρος μαρκετινγκ, εμείς κανονικά. Σημαίνει με το software ΟΡΙΖΕΙΣ το storage (εφαρμογή policy, αλλαγή πορείας του request)
- τρέχει σε πολλούς κόμβους
- αποτελείται από διακριτά κομμάτια
- κάνει CoW (εξήγησε ότι τα images είναι λίγα, τα VMs πολλά, όπως όταν ένα process κάνει fork)
- μπορούμε χρησιμοποιήσουμε ότι storage θέλουμε

Our solution

Archipelago

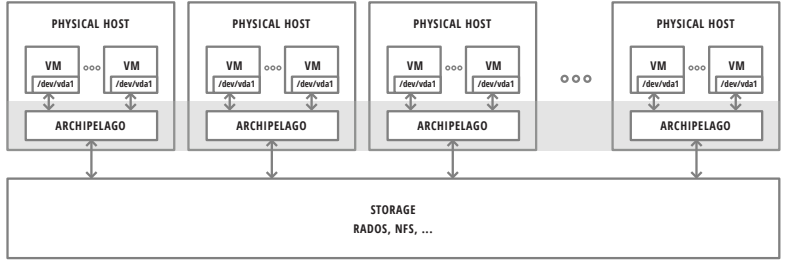

Key features: 1) Software-defined 2) Distributed 3) Modular 4) Copy-On-Write 5) Storage agnostic

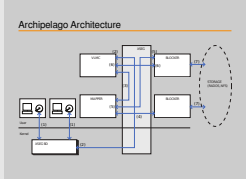

1. Το VM στέλνει αίτημα στο δίσκο του, ο δίσκος είναι εικονικός, θα το δει ο hypervisor (εξήγησε τι είναι ο hypervisor) και θα το στείλει στον δίσκο που το έχουμε πει. (xsegbd)
2. Ο xsegbd στέλνει το αίτημα στο userspace κομμάτι του Αρχιπελάγους το οποίο αποφαίνεται για τα αντικείμενα τα οποία αντιστοιχούν στο αίτημα. Συνοπτικά πως γίνεται αυτό:
   - Ο xsegbd στέλνει το αίτημα στο vmlmc
   - Ο vlmc συμβουλεύεται τα mappings του
3. μετά τα ζητάει από το storage μέσω των blockers

Archipelago Architecture

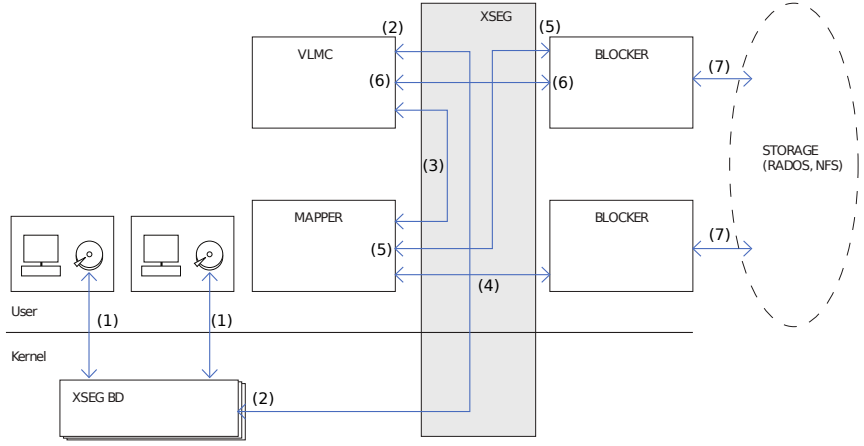

RADOS
The object store component of Ceph filesystem.
Key features:
- Replication
- Fault tolerance
- Self-management
- Scalability

Αν και είμαστε storage agnostic, χρησιμοποιούμε ένα σημαντικό storage backend, το RADOS, που μας δίνει τα εξής:

- Αντίγραφα ασφαλείας των δεδομένων
- Ανοχή στο χάσιμο αποθηκευτικών κόμβων
- Load balancing και αυτοδιαχείριση
- και τέλος ειναι επεκτάσιμο

CLICK! Αυτό το περίπλοκο σύστημα όμως δεν είναι αρκετά ταχύ. Παράδειγμα...
CLICK!

RADOS

The object store component of Ceph filesystem.

Key features:

- Replication
- Fault tolerance
- Self-management
- Scalability

RADOS
The object store component of Ceph filesystem.
Key features:
- Replication
- Fault tolerance
- Self-management
- Scalability
Speed issues:
VM with page-cache: > 90MB/s, < 1ms
VM without page-cache: < 7MB/s, ~10ms

Αν και είμαστε storage agnostic, χρησιμοποιούμε ένα σημαντικό storage backend, το RADOS, που μας δίνει τα εξής:

- Αντίγραφα ασφαλείας των δεδομένων
- Ανοχή στο χάσιμο αποθηκευτικών κόμβων
- Load balancing και αυτοδιαχείριση
- και τέλος ειναι επεκτάσιμο

CLICK! Αυτό το περίπλοκο σύστημα όμως δεν είναι αρκετά ταχύ. Παράδειγμα...
CLICK!

RADOS

The object store component of Ceph filesystem.

Key features:

- Replication
- Fault tolerance
- Self-management
- Scalability

Speed issues:
VM with page-cache: > 90MB/s, < 1ms
VM without page-cache: < 7MB/s, ~10ms

RADOS
The object store component of Ceph filesystem.
Key features:
- Replication
- Fault tolerance
- Self-management
- Scalability
Speed issues:
VM with page-cache: > 90MB/s, < 1ms
VM without page-cache: < 7MB/s, ~10ms
Thesis goal: make this faster.

Αν και είμαστε storage agnostic, χρησιμοποιούμε ένα σημαντικό storage backend, το RADOS, που μας δίνει τα εξής:

- Αντίγραφα ασφαλείας των δεδομένων
- Ανοχή στο χάσιμο αποθηκευτικών κόμβων
- Load balancing και αυτοδιαχείριση
- και τέλος ειναι επεκτάσιμο

CLICK! Αυτό το περίπλοκο σύστημα όμως δεν είναι αρκετά ταχύ. Παράδειγμα...
CLICK!

RADOS

The object store component of Ceph filesystem.

Key features:

- Replication
- Fault tolerance
- Self-management
- Scalability

Speed issues:
VM with page-cache: > 90MB/s, < 1ms
VM without page-cache: < 7MB/s, ~10ms

Thesis goal: make this faster.

Table of Contents

Intro

Solution: Caching

Caching is:
- We have a slow medium
- Add a fast medium in a data path
- Transparently store the data that are intended for the slower medium.
- Profit: later accesses to the same data are faster

Sounds familiar?

1. Η κλασσική λύση σε τέτοια προβλήματα είναι η χρήση ενός γρηγορότερου αποθηκευτικού μέσου για caching.
2. Για όσους δεν ξέρουν τι σημαίνει caching, θα το εξηγήσουμε συνοπτικά: έχεις ροή, αργό μέσο, βάζεις ένα γρήγορο, speedup
3. Προφανώς αυτό το concept είναι γνωστό. Από που;

Intro

Solution: Caching

Caching is:

- We have a slow medium
- Add a fast medium in a data path
- Transparently store the data that are intended for the slower medium.
- Profit: later accesses to the same data are faster

Sounds familiar?

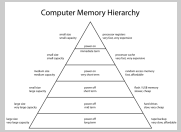

1. Από το ιεραρχικό μοντέλο του υπολογιστή: cpu cache vs ram, ram vs disk

Caching

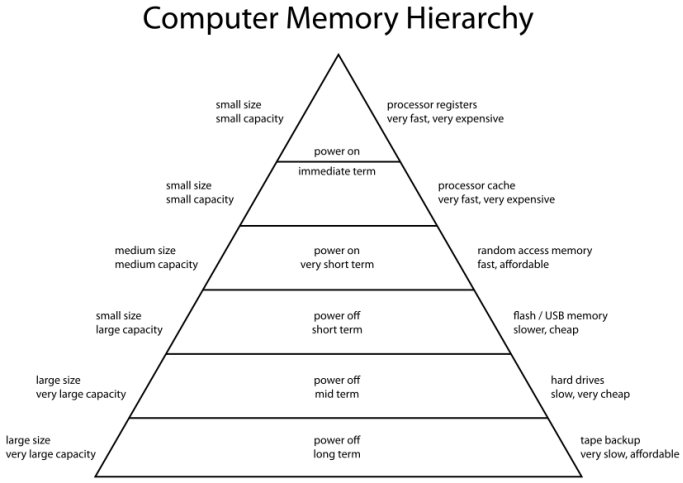

That's because every PC is built that way.

Is there anything to help us?

FACT: We are not the first to have speed issues
Facebook, Twitter, Dropbox, every one has hit and surpassed their limits.

There are solutions separated in two categories:
- Block-based caching
- Object-based caching

1. Τώρα που ξέρουμε τη λύση, υπάρχει κάτι που μπορούμε να κάνουμε;
2. Υπάρχει κάτι έτοιμο; NAI
3. Δυο κατηγορίες:
   - βλέπουν τα δεδομένα σαν blocks ενός δίσκου
   - βλέπουν τα δεδομένα σαν κομμάτια αντικειμένων

   Διαφορά: TODO:

Caching

Is there anything to help us?

FACT: We are not the first to have speed issues
Facebook, Twitter, Dropbox, every one has hit and surpassed their limits.

There are solutions separated in two categories:
- Block-based caching
- Object-based caching

Block-based caching solutions

Most notable examples:
- Bcache
- Flashcache
- EnhanceIO

Typically scale-up solutions.

Pros: Simple, scale-up
Cons: Unaware of CoW, kernel solutions

1. Δε θα επεκταθούμε γιατί έχουν κάποια βασικά κοινά:
   - Kernel modules
   - expose εικονικά block devices που δείχνουν σε γρήγορα μέσα
   - Καθαρά caching μηχανισμοί με policies
2. Εξήγησε που μπαίνουν (xsegbd). ΠΗΓΑΙΝΕ στο archipelago
3. Παρότι είναι αρκετά απλοί, δε γνωρίζουν την CoW πολιτική άρα χάνουν χώρο και είναι στον kernel (που δε θέλουμε)

Block-based caching solutions

Most notable examples:

- Bcache
- Flashcache
- EnhanceIO

Typically scale-up solutions.

Pros: Simple, scale-up
Cons: Unaware of CoW, kernel solutions

Object-based caching solutions

Most notable examples:
- Memcached
- Couchbase

Typically scale-out solutions

Pros: Distributed with no SPOF, can utilize unneeded RAM
Cons: Memcached has no persistence, Couchbase cannot use RADOS as its backend, more suitable for databases

Τα πράγματα γίνονται πιο ενδιαφέροντα εδώ:

- Κατανεμημένα συστήμα χωρίς ενιαίο σημείο αποτυχίας (SPOF), μπορούν να τρέχουν εκτός host οπότε δεν το επιβαρύνουν
- Memcached δε διατηρεί τα δεδομένα, couchbase δεν μπορεί να μιλήσει με rados

Object-based caching solutions

Most notable examples:

- Memcached
- Couchbase

Typically scale-out solutions

Pros: Distributed with no SPOF, can utilize unneeded RAM
Cons: Memcached has no persistence, Couchbase cannot use RADOS as its backend, more suitable for databases

Page-cache?

What if we used the page-cache?

Pros: Easy to activate, tested, very fast
Cons: Unaware of CoW, no control over it, practically kernel solution

Αν χρησιμοποιούσαμε την page-cacheΕύκολη λύση, σταθερή και γρήγορη. Όμως, δεν καταλαβαίνει από COW, είναι προσκολλημένη σε ένα block device

Page-cache?

What if we used the page-cache?

Pros: Easy to activate, tested, very fast
Cons: Unaware of CoW, no control over it, practically kernel solution

Conclusions
- Most solutions far from Archipelago's logic
- Others not suited for storage and more suited for databases
- Block-based caching might be good for the storage backend
- Must implement our own solution

TODO:

Conclusions

- Most solutions far from Archipelago's logic
- Others not suited for storage and more suited for databases
- Block-based caching might be good for the storage backend
- Must implement our own solution

Table of Contents

Requirements

Design goals for cached:
- Create something close to the Archipelago logic
- Measure the best possible performance we can get

Stricter requirements for cached:
- Nativity
- Pluggability
- In-memory
- Low indexing overhead

Επιλέξαμε λοιπόν να δημιουργήσαμε τη δική μας λύση. Την ονομάσαμε cached από το cache daemonΟρίσαμε τους εξής γενικούς στόχους:

- Δημιουργία ενός peer κοντά στη λογική του Archipelago
- Η υλοποίηση να είναι όσο το δυνατόν πιο γρήγορη για να δουμε αν μια Αρχιπελαγική λύση μας βοηθάει

Ακόμα, θέσαμε κάποιες πιο αυστηρές απαιτήσεις για την υλοποίηση μας: 1)να είναι peer του Archipelago, 2) να μπορεί να ενεργοποιείται και να απενεργοποιείται σε ένα σύστημα που τρέχει,3)να χρησιμοποιεί τη RAM, 4)ο indexing μηχανισμός να είναι γρήγορος

Requirements

Design goals for cached:

- Create something close to the Archipelago logic
- Measure the best possible performance we can get

Stricter requirements for cached:

- Nativity
- Pluggability
- In-memory
- Low indexing overhead

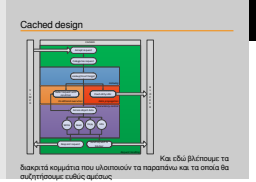

Εδώ βλέπουμε το design του cached. Ο cached μπαίνει ανάμεσα στον vmlc και στον blocker και cach-άρει ότι άιτημα για αντικείμενα πάει στο storageΟι εργασίες του cached χωρίζονται σε 5 κατηγορίες:item

1. Στην διαχείριση των αιτημάτων από και προς vlmc, blocker
2. Στο indexing (εύρεση και καταχώρηση) των αντικειμένων
3. Στην ασύγχρονη ή κατά όρους εκτέλεση εργασιών
4. Στην ασφαλή μετάδοση των cacharισμένων δεδομένων στο storage
5. Καθώς επίσης και στην ασφαλή επεξεργασία των cacharισμένων δεδομένων
6. CLICK!

Cached design

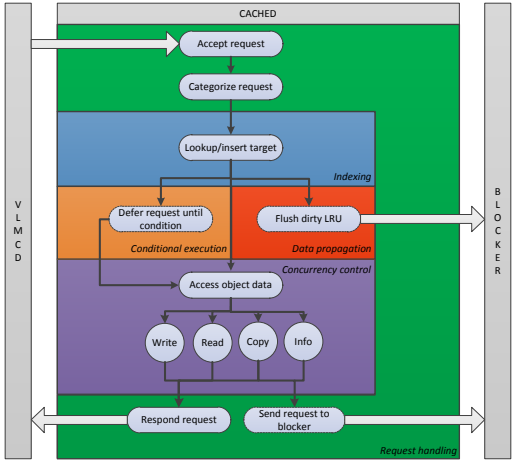

Και εδώ βλέπουμε τα διακριτά κομμάτια που υλοποιούν τα πα[illegible]άνω και τα οποία θα συζητήσουμε ευθύς αμέσως

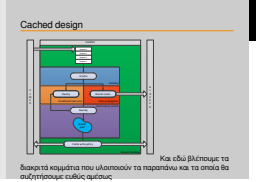

Εδώ βλέπουμε το design του cached. Ο cached μπαίνει ανάμεσα στον vmlc και στον blocker και cach-άρει ότι άιτημα για αντικείμενα πάει στο storageΟι εργασίες του cached χωρίζονται σε 5 κατηγορίες:item

1. Στην διαχείριση των αιτημάτων από και προς vlmc, blocker
2. Στο indexing (εύρεση και καταχώρηση) των αντικειμένων
3. Στην ασύγχρονη ή κατά όρους εκτέλεση εργασιών
4. Στην ασφαλή μετάδοση των cacharισμένων δεδομένων στο storage
5. Καθώς επίσης και στην ασφαλή επεξεργασία των cacharισμένων δεδομένων
6. CLICK!

Cached design

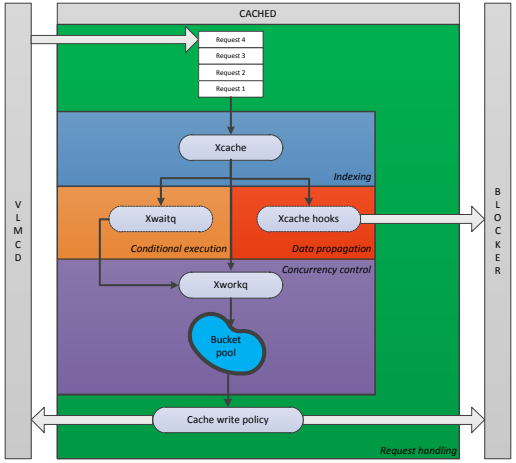

Και εδώ βλέπουμε τα διακριτά κομμάτια που υλοποιούν τα παραπάνω και τα οποία θα συζητήσουμε ευθύς αμέσως

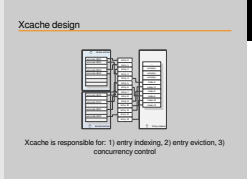

1. Αυτό είναι το xcache, που είναι υπεύθυνο για την
   - Εύρεση και καταχώριση των αντικειμένων
   - Έξωση αντικειμένων από την cache με τη χρήση LRU
   - Χειρισμό πολλαπλών threads
2. Εχουμε ένα hash table <αυτό> που κρατάει τα ονόματα των αντικειμένων. Ο αποθηκευτικός τους χώρος είναι preallocated και είναι <αυτό>. Σε αυτό το χώρο, η αναφορά γίνεται με δείκτες. Ο ελεύθερος χώρος είναι στη στοιβα αυτή. Τέλος, όταν ένα αντικείμενο φύγει, μένει σε αυτό το hash table μεχρι να το ξαναζητήσουν ή να το διωχτεί
3. CLICK!
4. Κάθε item έχει ένα reference counter για να ξέρουμε πόσοι το χρησιμοποιούν, όνομα, lru

Xcache design

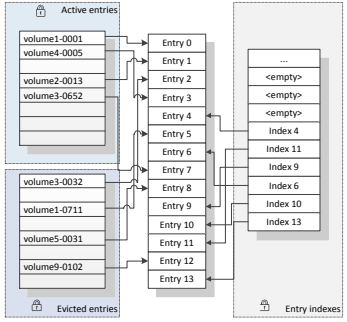

Xcache is responsible for: 1) entry indexing, 2) entry eviction, 3) concurrency control

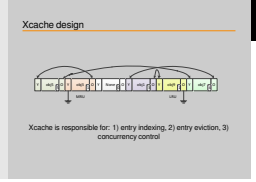

1. Αυτό είναι το xcache, που είναι υπεύθυνο για την
   - Εύρεση και καταχώριση των αντικειμένων
   - Έξωση αντικειμένων από την cache με τη χρήση LRU
   - Χειρισμό πολλαπλών threads
2. Εχουμε ένα hash table <αυτό> που κρατάει τα ονόματα των αντικειμένων. Ο αποθηκευτικός τους χώρος είναι preallocated και είναι <αυτό>. Σε αυτό το χώρο, η αναφορά γίνεται με δείκτες. Ο ελεύθερος χώρος είναι στη στοιβα αυτή. Τέλος, όταν ένα αντικείμενο φύγει, μένει σε αυτό το hash table μεχρι να το ξαναζητήσουν ή να το διωχτεί
3. CLICK!
4. Κάθε item έχει ένα reference counter για να ξέρουμε πόσοι το χρησιμοποιούν, όνομα, lru

Xcache design

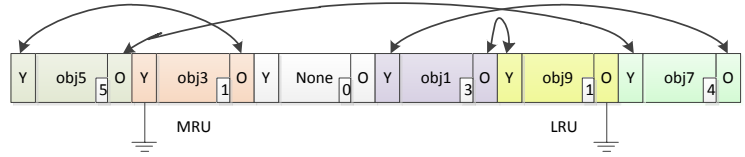

Xcache is responsible for: 1) entry indexing, 2) entry eviction, 3) concurrency control

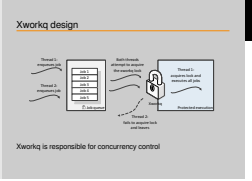

1. xworkq υπεύθυνο για την ασφαλή επεξεργασία των δεδομένων ενός αντικείμενου.
2. Το spinning είναι αργό, όλοι τοποθετούν μια δουλειά, ένας την εκτελεί.

Xworkq design

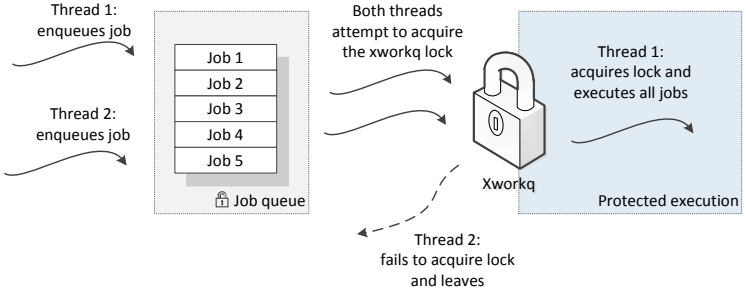

Xworkq is responsible for concurrency control

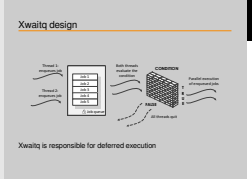

Xwaitq design

1. xwaitq υπεύθυνο για την κατά συνθήκη εκτελεση εργασιών
2. Αν π.χ. μας τελειώσει ο χώρος, δεν μπορούμε να περιμένουμε σύγχρονα. Το thread μπορεί να τοποθετήσει μια δουλειά και μετά να εκτελέσει κάτι άλλο

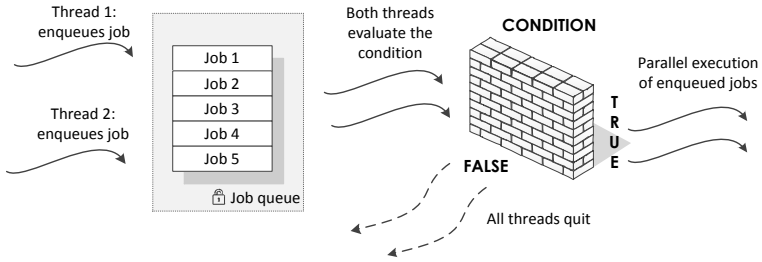

Xwaitq is responsible for deferred execution

Bucket pool
When an object is indexed, it does not have immediate access to 4MB size of data because:
- RAM is limited
- Leads to small number of entries

Ideally, we want to:
- Decouple the objects from their data
- Cache unlimited objects but put a limit on their data

Solution:
- Preallocated data space
- Every object request a bucket (typically 4KB)
- When an object is evicted, its buckets are reclaimed

1. Το ότι κάνουμε index ένα object δε σημαίνει ότι κατ'ευθείαν μπορούμε να γράψουμε σε αυτό
2. Δεν υπάρχει τόση RAM και ακόμα και ως αποτέλεσμα, θα cacháραμε μικρό αριθμό από objects
3. Ιδανικά θέλουμε να διαχωρίσουμε την καταχώρη/όνομα του αντικειμένου από τα δεδομένα του. Δυνητικά θα μπορούμε να καταχωρούμε πάρα πολλά αντικείμενα αλλά θα έχουμε μικρότερο χώρο
4. Preallocated χώρος, όλοι παίρνουν indexes από αυτό (Θυμίζει xcache

Bucket pool

When an object is indexed, it does not have immediate access to 4MB size of data because:

- RAM is limited
- Leads to small number of entries

Ideally, we want to:

- Decouple the objects from their data
- Cache unlimited objects but put a limit on their data

Solution:

- Preallocated data space
- Every object request a bucket (typically 4KB)
- When an object is evicted, its buckets are reclaimed

Other important cached tasks

Several other key-tasks are:
- Book-keeping
- Cache write policy
- Asynchronous task execution
- Data propagation

Το cached είναι επίσης επιφορτισμένο και με άλλες δουλειές όπως:

- Κρατάει στατιστικά (πόσα entries είναι dirty, πόσα buckets έχει κάνει allocate ένα entry
- Εφαρμόζει writeback/writethrough πολιτική
- Φρόντίζει ώστε οι εργασίες να μπορούν να γίνουν ασύγχρονα
- Και φυσικά φροντίζει τα δεδομένα να γράφονται σωστά στο storage

Other important cached tasks

Several other key-tasks are:

- Book-keeping
- Cache write policy
- Asynchronous task execution
- Data propagation

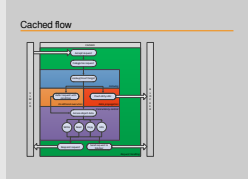

1. Εδώ παίζεις με τα slides
2. Θα παρουσιάσουμε πολύ γρήγορα τη ροή ενός αιτήματος στον cached
3. Έρχεται request, το κάνουμε index, μπαίνουμε στη workq και πειράζουμε τα δεδομένα του και ανάλογα το cache policy το γράφουμε πίσω στον blocker αλλιώς τελειώσαμε
4. Optional σεναρια:
   - Αν γίνει ένα eviction, πρέπει να γράψουμε τα δεδομένα του πίσω με ασφάλεια. Επειδή το αντικείμενο μπορει να καταχωρηθεί, να μπει και να ξαναβγεί, πρέπει να είμαστε προσεκτικοί
   - Αν ξεμείνουμε από πόρους (χώρο στο hash table, buckets κτλ, πρέπει να συνεχίσουμε μονο όταν μπορούμε

Cached flow

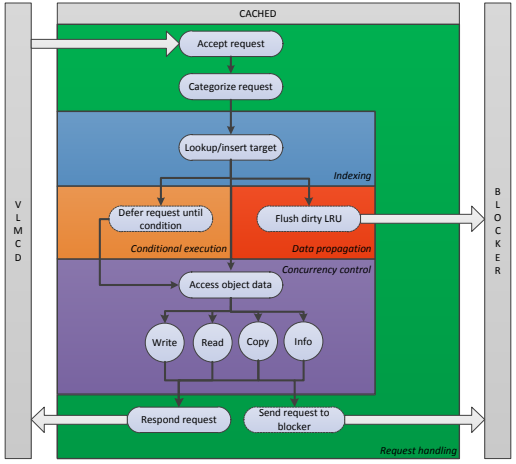

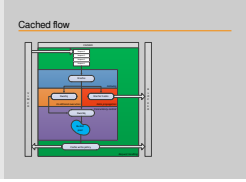

1. Εδώ παίζεις με τα slides
2. Θα παρουσιάσουμε πολύ γρήγορα τη ροή ενός αιτήματος στον cached
3. Έρχεται request, το κάνουμε index, μπαίνουμε στη workq και πειράζουμε τα δεδομένα του και ανάλογα το cache policy το γράφουμε πίσω στον blocker αλλιώς τελειώσαμε
4. Optional σεναρια:
   - Αν γίνει ένα eviction, πρέπει να γράψουμε τα δεδομένα του πίσω με ασφάλεια. Επειδή το αντικείμενο μπορει να καταχωρηθεί, να μπει και να ξαναβγεί, πρέπει να είμαστε προσεκτικοί
   - Αν ξεμείνουμε από πόρους (χώρο στο hash table, buckets κτλ, πρέπει να συνεχίσουμε μονο όταν μπορούμε

Cached flow

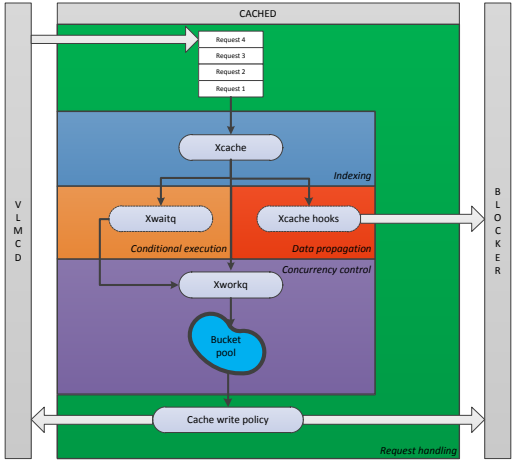

Table of Contents
Introduction
VM Volume storage
Caching
Cached design
Cached evaluation
Synapsed
Conclusion

Table of Contents

Benchmark methodology

We have conducted exhaustive benchmarks.
They are separated in three categories:
- Comparison between cached and sosd
  - Peak behavior
  - Sustained behavior
- Internal comparison of cached
  - Multithreading overhead
  - Indexing mechanism overhead
- Evaluation of VM/Archipelago

Benchmark methodology

We have conducted exhaustive benchmarks.
They are separated in three categories:

- Comparison between cached and sosd
  - Peak behavior
  - Sustained behavior
- Internal comparison of cached
  - Multithreading overhead
  - Indexing mechanism overhead
- Evaluation of VM/Archipelago

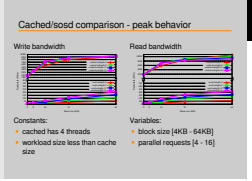

Cached/sosd comparison - peak behavior

Write bandwidth

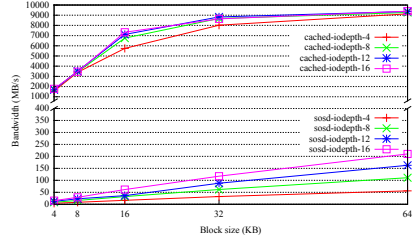

Read bandwidth

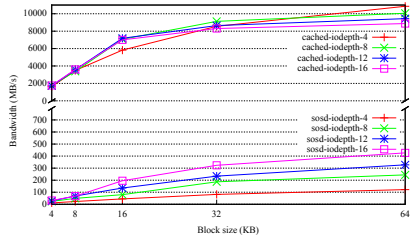

Constants:

- cached has 4 threads
- workload size less than cache size

Variables:

- block size [4KB - 64KB]
- parallel requests [4 - 16]

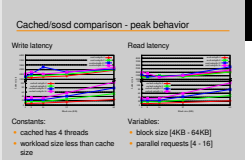

Cached/sosd comparison - peak behavior

Write latency

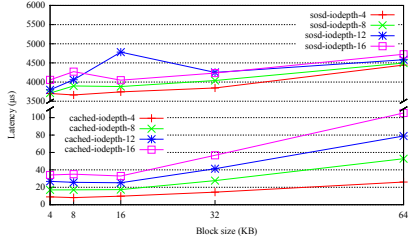

Read latency

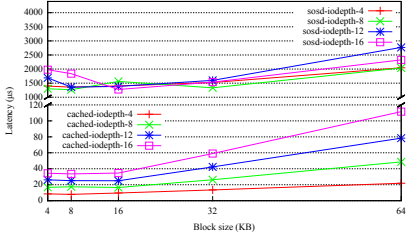

Constants:

- cached has 4 threads
- workload size less than cache size

Variables:

- block size [4KB - 64KB]
- parallel requests [4 - 16]

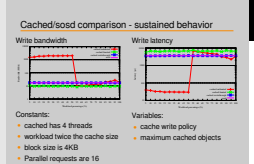

Cached/sosd comparison - sustained behavior

Write bandwidth

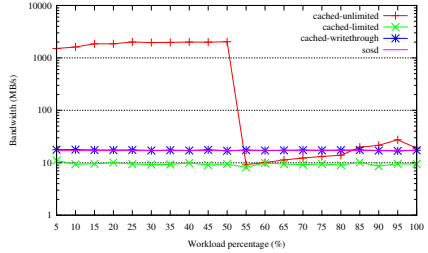

Write latency

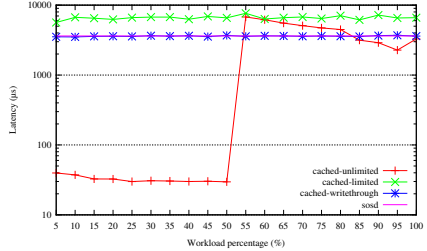

Constants:

- cached has 4 threads
- workload twice the cache size
- block size is 4KB
- Parallel requests are 16

Variables:

- cache write policy
- maximum cached objects

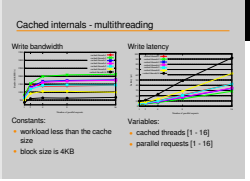

Cached internals - multithreading

Write bandwidth

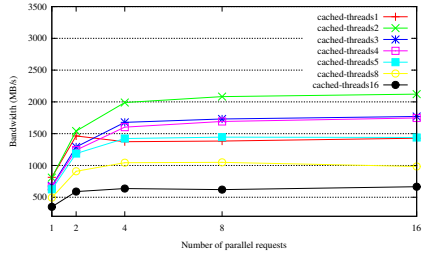

Write latency

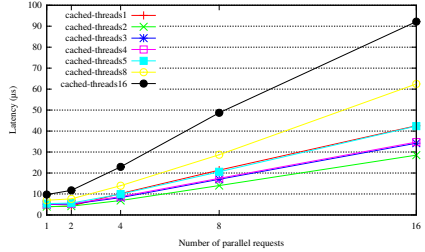

Constants:

- workload less than the cache size
- block size is 4KB

Variables:

- cached threads [1 - 16]
- parallel requests [1 - 16]

Cached internals - indexing
Latency of cold cache vs. warm cache
Constants:
- workload less than the cache size
- block size is 4KB
- no threads or parallel requests
Variables:
- number of objects [128k - 1G]

Cached internals - indexing

Latency of cold cache vs. warm cache

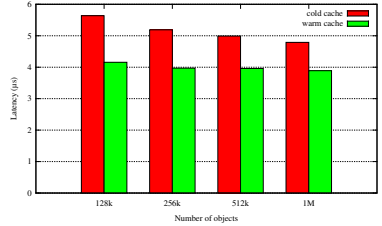

Constants:

- workload less than the cache size
- block size is 4KB
- no threads or parallel requests

Variables:

- number of objects [128k - 1G]

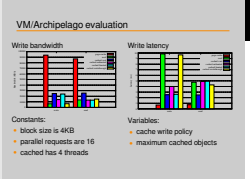

VM/Archipelago evaluation

Write bandwidth

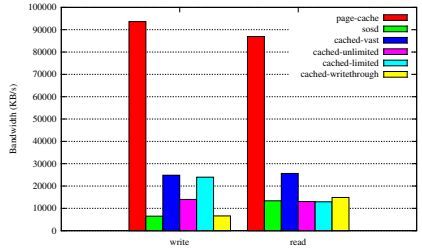

Write latency

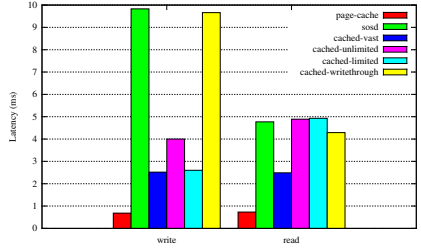

Constants:

- block size is 4KB
- parallel requests are 16
- cached has 4 threads

Variables:

- cache write policy
- maximum cached objects

Table of Contents
Introduction
VM Volume storage
Caching
Cached design
Cached evaluation
Synapsed
Conclusion

Table of Contents

Introduction

Previous results show that:
- There is high lock contention
- The amount of RAM is important

If cached remains at the host, it will:
- Compete for CPU time
- Use a fraction of the host's RAM

Idea: what if cached ran on storage nodes?

Introduction

Previous results show that:

- There is high lock contention
- The amount of RAM is important

If cached remains at the host, it will:

- Compete for CPU time
- Use a fraction of the host's RAM

Idea: what if cached ran on storage nodes?

If cached was on storage nodes, the pros would be:
- Access to more RAM
- Major step towards a distributed cache

On the other hand, the cons would be:
- Network bottleneck
- Bigger complexity

Archipelago is network-unaware. Must create a proof-of-concept network peer to help us in this task.

Synapsed

If cached was on storage nodes, the pros would be:

- Access to more RAM
- Major step towards a distributed cache

On the other hand, the cons would be:

- Network bottleneck
- Bigger complexity

Archipelago is network-unaware. Must create a proof-of-concept network peer to help us in this task.

Synapsed design

Synapsed is designed to do the following:
- Connect two Archipelago peers over network
- Forward read/write XSEG requests
- Use the TCP protocol
- Integrate with the Archipelago signaling mechanism
- Use zero-copy methods

Replication should be trivial to implement, but it is currently missing.

Synapsed design

Synapsed is designed to do the following:

- Connect two Archipelago peers over network
- Forward read/write XSEG requests
- Use the TCP protocol
- Integrate with the Archipelago signaling mechanism
- Use zero-copy methods

Replication should be trivial to implement, but it is currently missing.

Benchmark preamble

The most important part is that synapsed works. We are **now** able to run cached or part of Archipelago in the storage nodes.

However, let's check its performance.
We will attempt to run most of the previous scenarios using synapsed this time.

Note, synapsed is proof-of-concept and not performance-tuned.
Also, the tested configuration uses a 1Gbit connection.

Benchmark preamble

The most important part is that synapsed works. We are **now** able to run cached or part of Archipelago in the storage nodes.

However, let's check its performance.
We will attempt to run most of the previous scenarios using synapsed this time.

Note, synapsed is proof-of-concept and not performance-tuned.
Also, the tested configuration uses a 1Gbit connection.

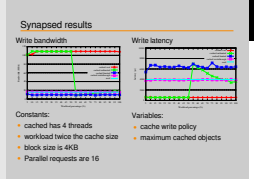

Synapsed results

Write bandwidth

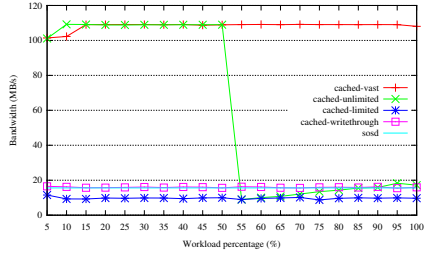

Write latency

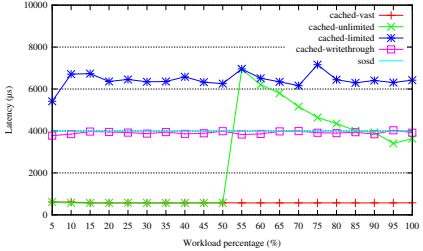

Constants:

- cached has 4 threads
- workload twice the cache size
- block size is 4KB
- Parallel requests are 16

Variables:

- cache write policy
- maximum cached objects

Table of Contents

Concluding remarks

We close this presentation with the following remarks:
- Cached and synapsed have covered important Archipelago needs
- Synthetic benchmarks show that cached can achieve 200x better performance than sosd
- In more real-life scenarios, cached speeds Archipelago up to 400%
- Synapsed can bridge two peers over network with minimum latency

Concluding remarks

We close this presentation with the following remarks:

- Cached and synapsed have covered important Archipelago needs
- Synthetic benchmarks show that cached can achieve 200x better performance than sosd
- In more real-life scenarios, cached speeds Archipelago up to 400%
- Synapsed can bridge two peers over network with minimum latency

Future work

Future work is happening as we speak:
- Full CoW support
- Namespace support
- Support for different policies and limits per volume

Future work

Future work is happening as we speak:

- Full CoW support
- Namespace support
- Support for different policies and limits per volume